

Model Documentation, Previsão Climática de Precipitação sobre a América do Sul

Documento no formato *Kaggle Winning Model Documentation Guidelines*. Complementa o README.md do repositório, que contém a discussão técnica completa.

A1. Background on you/your team

Competition: Previsão Climática de Precipitação sobre a América do Sul, Hackathon WorCAP 2026 (INPE) **Team name:** Rain-NP-Hard **Public leaderboard:** RMSE 1,48895, 2º lugar **Private leaderboard:** (após divulgação)

Membros

membro	localização	e-mail	formação / experiência	horas
Leonardo Arazo de Oliveira Araújo	São José dos Campos, SP	arazo.leonardo@unifesp.br	Graduando em Ciência da Computação, UNIFESP	~50 h
Prof. Dr. Didier Augusto Vega-Oliveros	São José dos Campos, SP	didier.vega@unifesp.br	Professor Doutor, UNIFESP	~50 h
Alex Junio Ribeiro Campos	São José dos Campos, SP	alex.campos@unifesp.br	Mestrando em Ciência da Computação, UNIFESP	~50 h

Motivação da equipe: o problema une dois interesses do grupo, aprendizado de máquina aplicado a geociências e a pergunta de quanto sinal um modelo estatístico consegue extrair de um sistema caótico com um mês de antecedência. A experiência anterior do grupo com estimativa de precipitação por satélite (IMERG/GMI) informou várias decisões de projeto, em particular a de não testar arquiteturas de alta capacidade.

A2. Summary

A solução decompõe a precipitação em climatologia mais anomalia e modela apenas a anomalia. Dois modelos são combinados: um **LightGBM global** (um modelo para toda a grade, com lat/lon como atributos) e uma **regressão ridge local por ponto de grade**. Ambos recebem como preditores as anomalias de reanálise ERA5 entregues pela competição, índices de temperatura da superfície do mar da NOAA, e, o componente decisivo, as previsões mensais de **nove sistemas de previsão**

sazonal de sete centros operacionais (NCEP, GFDL, NASA, ECCO, ECMWF, UKMO, Météo-France, DWD, CMCC), usadas como *Model Output Statistics*. As duas formulações têm correlação de 0,85 entre suas previsões e são combinadas em peso fixo 0,63/0,37, validado por *walk-forward*.

Ferramentas: Python 3.12, LightGBM 4.7, xarray, scikit-learn. Treino completo em ~40 minutos num nó de CPU (16 núcleos); predição em ~2 minutos.

A3. Features Selection / Engineering

Como as features foram selecionadas

Por validação *walk-forward* em cinco cortes temporais (1997, 2002, 2007, 2012, 2017), cada um avaliando os cinco anos seguintes. Uma feature ou grupo entrava se melhorasse o ganho sobre a climatologia na maioria dos folds; era rejeitada caso contrário. Dezoito hipóteses foram testadas; doze rejeitadas (tabela completa na seção 7 do README).

As features mais importantes

Importância medida como fração do ganho total do LightGBM (*gain*), agregada por grupo:

grupo	% do ganho	conteúdo
previsões dinâmicas	41	anomalias dos 9 sistemas em 2 leads, médias, dispersão entre membros
grande escala (reanálise)	28	8 EOFs por grupo de variáveis (pressão, geopotencial, circulação, umidade, fluxo), defasagens 1–3
estáticas	13	lat, lon, climatologia do ponto no mês-alvo, climatologia anual
locais (reanálise)	10	anomalias das 9 covariáveis + transporte de umidade
índices de TSM	7	Niño 1+2/3.4/4, ONI, SOI, PDO, dipolo do Atlântico
sazonais	1	sin/cos do mês

Gráfico das 20 features individuais mais importantes: `figuras/importancia_top20.png` (gerado por `src/19_importancia_plot.py`).

Features únicas ou não óbvias

- Previsões de modelos dinâmicos como preditores.** Cada sistema é anomalizado contra a climatologia do próprio *hindcast*, por ponto e mês calendário, o que remove seu viés médio antes da combinação. Onde um sistema não existe (treino anterior ao *hindcast*), a coluna recebe zero e um indicador marca a ausência.
- Dipolo do Atlântico (TNA–TSA) em vez das TSMs absolutas.** As absolutas estavam fora da distribuição de treino em 2023–24 (58% e 75% das linhas além do p99 histórico); o gradiente cancela o aquecimento uniforme e fica dentro da distribuição.

3. **Transporte de umidade** ($q \cdot u$, $q \cdot v$, convergência) construído a partir de umidade específica e vento em 850 hPa, porque a variável fisicamente mais direta para chuva não foi entregue.
4. **Lag-ensemble**: a previsão emitida um mês antes para o mesmo alvo entra como coluna separada. A média simples com o lead mais antigo piora; o LightGBM aprende a ponderar.

Features excluídas deliberadamente

A precipitação do mês anterior, existe no treino, mas no teste só há um valor constante. Treinar com uma feature ausente na inferência seria falha silenciosa.

A4. Training Method(s)

Alvo

$\text{anomalia} = \text{precipitação} - \text{climatologia_v3}(\text{ponto}, \text{mês-alvo})$, onde a climatologia v3 mistura uma janela de 24 anos com o período completo e aplica tendência local encolhida ($k=0,15$).
Reajustada dentro de cada fold do CV para evitar vazamento.

Modelo global: LightGBM

```
objective=l2, num_leaves=63, learning_rate=0.02, n_estimators=1200,
min_child_samples=200, feature_fraction=0.7, bagging_fraction=0.7,
bagging_freq=1, lambda_l2=5, random_state=42
```

Ajuste final: média de 5 sementes, cada uma sobre 5 milhões de linhas amostradas do treino (subamostragem espacial de fator 3 na grade; a predição é feita na grade cheia de 78.561 pontos).

Modelo local: ridge por ponto

8.787 regressões ridge ($\lambda=30$), uma por ponto de grade, sobre 31 colunas: anomalias dos sistemas dinâmicos em dois leads, médias, indicadores de disponibilidade, sin/cos do mês. Solução fechada; segundos de execução. Na grade cheia do teste, cada ponto usa os coeficientes do ponto de treino mais próximo.

Combinação

$\text{anomalia_final} = 0,63 \cdot \text{anom_lgbm} + 0,37 \cdot \text{anom_ridge}$. O peso foi ajustado em quatro folds e aplicado no quinto; saiu idêntico (0,63–0,64) em todos.

Encolhimento

$\text{previsão} = \text{climatologia_v3} + \alpha \cdot \text{anomalia_final}$, com $\alpha = 1,044$ (média dos folds; o modelo está calibrado, inclinação 1,016 por decil).

Sem ensemble de outros aprendizes

LightGBM + Ridge + MLP foi testado antes da entrada dos dinâmicos e rejeitado. Com os dinâmicos, o ridge *pontual* (não global) trouxe diversidade real.

A5. Interesting findings

1. Informação vale mais que modelo, por uma ordem de grandeza. A correlação de anomalia foi de 0,19 (só reanálise) para 0,53 (com nove sistemas dinâmicos). Dezoito hipóteses de modelagem testadas somaram menos de 3 pontos percentuais de ganho; a entrada de previsão dinâmica somou 13.

2. A validação cruzada divergiu do placar por um motivo físico, não estatístico. Entre as submissões 4 e 7, o CV melhorou cinco vezes e o placar piorou quatro. O diagnóstico mostrou que TNA e TSA absolutas estavam fora da distribuição de treino em 2023–24 (anos de oceano recorde). Árvores não extrapolam. A correção, usar o gradiente em vez das absolutas, resolveu, e o CV voltou a prever o placar nas seis rodadas seguintes.

3. O peso por recência, que melhorou o CV em cinco de cinco folds, piorou o placar em dois pares comparáveis. Descartava os El Niños fortes do passado, que são os análogos de 2023. Foi rejeitado pelo placar, não pelo CV.

4. O SEAS5 do ECMWF sozinho ($r=0,514$) supera a média dos três modelos americanos do NMME (0,431). E a média simples de nove sistemas (0,504) fica abaixo do SEAS5 isolado, média simples pesa igual um modelo de 0,51 e um de 0,29. A regressão aprende os pesos.

5. MOS local e ML global são complementares. O ridge por ponto sozinho é pior que o LightGBM (r 0,506 vs 0,525), mas a correlação entre as duas previsões é só 0,85. A combinação ganha 0,83 p.p., o maior ganho de modelagem do projeto.

O que não funcionou: mais componentes de EOF, defasagens longas, mais capacidade no LightGBM, busca de hiperparâmetros, subamostragem espacial mais densa, níveis superiores do ERA5, TSM em grade, α por mês. Todos documentados com números no README.

A6. Simple Features and Methods

Um modelo que atinge **~90% do desempenho final** com uma fração da complexidade:

- Climatologia simples (média por ponto e mês, todos os anos).
- LightGBM com parâmetros padrão sobre **apenas as anomalias dos cinco sistemas dinâmicos de maior habilidade** (SEAS5, CanSIPS, UKMO, CMCC, CFSv2) no lead 0,5, mais lat, lon e sin/cos do mês.
- Sem ridge, sem sementes múltiplas, sem índices de TSM, sem EOFs.

Estimativa: ganho de ~13% sobre a climatologia (contra 16% do modelo completo), RMSE público em torno de 1,56. Onze colunas em vez de 310.

Uma versão ainda mais simples, **só a média dos cinco sistemas, multiplicada por um α ajustado, somada à climatologia**, dá cerca de 80% do desempenho sem nenhum aprendizado de máquina. É a linha de base que qualquer solução com previsão dinâmica deve superar.

A7. Model Execution Time

Hardware: nó de CPU AMD EPYC, 16 núcleos alocados, 1,5 TB de RAM (pico de uso ~25 GB). Sem GPU. Sistema Linux, Python 3.12 via conda.

etapa	tempo
Preparação de dados (anomalias, EOFs, features, índices)	~15 min
Montagem das matrizes com os sistemas dinâmicos (13d)	~10 min
Validação walk-forward (5 folds)	~10 min
Treino final LightGBM (5 sementes × 5M linhas × 1200 árvores)	~22 min
Ridge pontual (8.787 regressões) + combinação	~12 min
Predição na grade cheia (1,9M linhas)	~2 min

Downloads externos (fora do cluster): NMME via IRI ~30 min; SEAS5 e C3S via Copernicus ~4 h de fila. Predição rápida com modelos salvos (`predict.py`): ~3 min.

A8. References

- Glahn, H. R. & Lowry, D. A. (1972). The Use of Model Output Statistics (MOS) in Objective Weather Forecasting. *J. Appl. Meteor.*, 11, 1203–1211.
- Hersbach, H. et al. (2020). The ERA5 global reanalysis. *Q. J. R. Meteorol. Soc.*, 146, 1999–2049.
- Johnson, S. J. et al. (2019). SEAS5: the new ECMWF seasonal forecast system. *Geosci. Model Dev.*, 12, 1087–1117.
- Ke, G. et al. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *NeurIPS*.
- Kirtman, B. P. et al. (2014). The North American Multimodel Ensemble. *Bull. Amer. Meteor. Soc.*, 95, 585–601.
- Murphy, A. H. (1988). Skill scores based on the mean square error. *Mon. Wea. Rev.*, 116, 2417–2424.

Dados: NOAA/PSL climate indices; NMME via IRI Data Library; ECMWF SEAS5 e C3S multi-system via Copernicus Climate Data Store (contém informação modificada do Copernicus Climate Change Service; nem a Comissão Europeia nem o ECMWF são responsáveis pelo uso feito).

Código: https://github.com/GPAM-ai/era5_precip, licença MIT.

B. Code (checklist)

item	arquivo	status
README com hardware, SO, software, como treinar, como prever, premissas	README.md + este documento	✓
requirements.txt com versões exatas	requirements.txt (gerado por pip freeze)	✓
Estrutura de diretórios	directory_structure.txt (find . -type d)	✓
Arquivo de configuração com caminhos	settings.json	✓
Ponto de entrada de preparação	prepare_data.py	✓
Ponto de entrada de treino	train.py	✓
Ponto de entrada de predição (modo rápido com modelo salvo)	predict.py	✓
Modelos treinados	dados_processados/modelo_final_*.pkl , ridge_pontual.pkl	✓
Semente fixa	42 em todos os pontos estocásticos	✓

Premissas do código: o diretório dados_processados/ deve existir e ser gravável; saidas/ idem. Os dados brutos da competição ficam no caminho indicado em settings.json . Os hindcasts dos sistemas dinâmicos (270–400 MB por sistema) não estão no repositório e são baixados por baixar_seas5.py e baixar_c3s.py numa máquina com acesso à internet.